Universidad Politécnica Metropolitana del Estado de Hidalgo (UPMH)

Detección de baches mediante Procesamiento Digital de Imágenes (PDI)

Profesor: Dr. Ernesto García Amaro

Alumna: Jessica Melani Romero Lora}

Asignatura: Sistemas de Visión Artificial

Maestría en Inteligencia Artificial

Link al repositorio de prácticas de la materia:

https://github.com/jessicaromero-ctrl/Artificial-Vision-System-s/tree/main/03-deteccion-baches

1. Introducción

El deterioro del pavimento es uno de los problemas de infraestructura más visibles en México. Los baches incrementan el riesgo de accidentes, ocasionan daños a los vehículos y dificultan la movilidad de peatones, automovilistas y usuarios del transporte público. El diagnóstico manual de la red vial es lento y costoso, por lo que un sistema que analice imágenes de carreteras y calles permite priorizar las intervenciones con base en evidencia visual.

Esta práctica aborda la fase de detección de regiones candidatas a bache mediante técnicas clásicas de Procesamiento Digital de Imágenes (PDI). Desde la perspectiva de un sistema de visión artificial, el enfoque clásico tiene una ventaja concreta: es determinista, de bajo costo computacional y fácil de explicar. Estas propiedades permiten reducir la región de análisis antes de invocar un modelo de Machine Learning o Deep Learning, lo que corresponde a un diseño híbrido.

El objetivo general es diseñar y evaluar un pipeline de PDI que caracterice imágenes de baches a partir de bordes, esquinas y binarización. Los objetivos específicos son los siguientes:

1. Convertir las imágenes del espacio de color BGR a escala de grises.
2. Estandarizar las dimensiones de las imágenes de entrada.
3. Aplicar técnicas de suavizado para reducir el ruido de textura del pavimento.
4. Detectar bordes con los operadores Sobel, Prewitt y Roberts, y compararlos cuantitativamente.
5. Detectar esquinas y puntos de interés con los detectores Harris y Shi-Tomasi.
6. Binarizar la imagen y evaluar la segmentación frente a las anotaciones del dataset.

El alcance de la práctica se limita al PDI clásico y a su evaluación contra anotaciones de referencia. No se incluye una etapa de clasificación con modelos de aprendizaje, que corresponde al trabajo futuro. El documento se organiza en un marco teórico con los fundamentos de cada etapa, un desarrollo que describe la implementación y los resultados, y un apartado de conclusiones con las limitaciones identificadas.

2. Marco teórico

2.1 Representación digital y espacio de color

Una imagen digital es una función discreta $I(x, y)$ que asigna a cada píxel una intensidad. OpenCV almacena las imágenes en color en el orden BGR. La escala de

grises es un canal que representa la luminancia, calculada como una combinación lineal ponderada de los canales de color:

$$Y(x, y) = 0.299\, R(x, y) + 0.587\, G(x, y) + 0.114\, B(x, y)$$

Esta reducción de tres canales a uno disminuye la carga computacional y elimina la dependencia del color, que en el pavimento aporta poca información discriminante frente a la forma y el contraste.

2.2 Estandarización geométrica

Las imágenes del dataset tienen resoluciones distintas. Para que las métricas sean comparables, es necesario llevarlas a una dimensión común. Un redimensionado directo modifica la relación de aspecto y deforma los baches. El letterbox conserva la relación de aspecto: se aplica una escala uniforme

$$s = min\left(\frac{S}{W}, \frac{S}{H}\right)$$

y el espacio sobrante se rellena con un valor constante. Las coordenadas de las anotaciones se transforman con la misma escala y el mismo desplazamiento.

2.3 Filtrado y suavizado

Un filtro lineal se implementa como una convolución entre la imagen y un núcleo K de tamaño $(2k + 1) \times (2k + 1)$:

$$I_s(x, y) = \sum_{i=-k}^{k} \sum_{j=-k}^{k} I(x + i, y + j)\, K(i, j)$$

El suavizado gaussiano utiliza un núcleo cuyos pesos siguen una distribución normal bidimensional de desviación σ:

$$G(x, y) = \frac{1}{2\pi\sigma^2} exp\left(-\frac{x^2+y^2}{2\sigma^2}\right)$$

Su efecto es atenuar las componentes de alta frecuencia, como la textura granular del asfalto, que de otro modo generaría bordes falsos. El filtro de mediana sustituye cada píxel por la mediana de su vecindad y conserva mejor las transiciones abruptas. El filtro bilateral pondera por distancia espacial y por similitud de intensidad, por lo que suaviza regiones homogéneas sin desdibujar los bordes.

2.4 Detección de bordes

Un borde es una región donde la intensidad cambia de forma abrupta. El gradiente de la imagen estima esa variación mediante derivadas parciales aproximadas por convolución con núcleos pequeños. La magnitud del gradiente se calcula como:

$$M(x,y) = \sqrt{G_x(x,y)^2 + G_y(x,y)^2}$$

Los tres operadores comparados difieren en el tamaño y los pesos de sus núcleos. Por ejemplo, el operador de Sobel utiliza los núcleos

$$G_x = [-1\,0\,1\;\; -2\,0\,2\;\; -1\,0\,1], \qquad G_y = [-1\;\; -2\;\; -1\;\; 0\;\; 0\;\; 0\;\; 1\;\; 2\;\; 1]$$

Roberts utiliza un núcleo 2×2 que evalúa diferencias diagonales. Prewitt utiliza un núcleo 3×3 con pesos uniformes. Sobel pondera con el doble de peso la fila o columna central, lo que aporta un suavizado implícito en la dirección perpendicular al gradiente. Como consecuencia, Roberts es el más sensible al ruido y Sobel el más robusto de los tres. Para obtener un mapa binario de bordes, la magnitud se normaliza a 0–255 y se binariza con el umbral de Otsu.

2.5 Detección de esquinas y puntos de interés

Una esquina es un punto donde el gradiente cambia de dirección de forma significativa. El detector de Harris analiza la matriz de autocorrelación M del gradiente en una vecindad y define una medida de respuesta:

$$R = det(M) - k\,tr(M)^2, \qquad k = 0.04$$

Un valor alto de R indica una esquina. El detector Shi-Tomasi utiliza como criterio el menor autovalor λ_{min} de M, que mide la intensidad del gradiente en la dirección más débil. Se acepta un punto cuando λ_{min} supera una fracción del máximo global, y se impone una distancia mínima entre puntos para evitar agrupaciones. Ambos métodos son estables frente a pequeñas traslaciones, pero su número de puntos depende fuertemente de los parámetros de umbral.

2.6 Binarización y morfología matemática

La binarización asigna a cada píxel uno de dos valores según un umbral. El método de Otsu selecciona el umbral t^* que maximiza la varianza entre clases:

$$\sigma_B^2(t) = \omega_0(t)\,\omega_1(t)\,[\mu_0(t) - \mu_1(t)]^2, \qquad t^* = arg\,\max_t\,\sigma_B^2(t)$$

Este criterio funciona bien cuando el histograma es bimodal y la iluminación es uniforme. Cuando la iluminación varía dentro de la imagen, el umbral adaptativo calcula un umbral local para cada píxel a partir de una ventana. Las máscaras resultantes contienen ruido en forma de píxeles aislados y huecos pequeños. La apertura (erosión seguida de dilatación) elimina los primeros y el cierre (dilatación seguida de erosión) rellena los segundos.

2.7 Métricas de evaluación

La calidad de una segmentación se mide frente a una máscara de referencia A, construida a partir de las cajas anotadas. La intersección sobre la unión (IoU) es la métrica estándar de solapamiento:

$$IoU(P, A) = \frac{|P \cap A|}{|P \cup A|}$$

Para los bordes y las esquinas se utilizan métricas de localización dentro de la región de interés (ROI). La energía en ROI es la fracción de la magnitud del gradiente que cae dentro de las cajas. La precisión en ROI es la fracción de píxeles de borde que caen dentro de las cajas. Estas métricas solo son interpretables frente a una línea base, por ejemplo, la fracción del área de la imagen que ocupan las cajas, porque un operador aleatorio obtendría valores cercanos a esa fracción.

3. Desarrollo de la práctica

3.1 Entorno de trabajo

La práctica se desarrolló en un equipo MacBook Air con macOS, utilizando Python en un entorno virtual aislado. Las dependencias principales son OpenCV (opencv-python) para el procesamiento de imágenes, NumPy para el álgebra de matrices, Matplotlib para las gráficas y kagglehub para la descarga del dataset. El código se organizó en un repositorio de Git con la estructura de carpetas de la asignatura, y los archivos de resultados se excluyen del control de versiones, salvo los archivos de métricas y las figuras.

3.2 Dataset

Se utilizó el conjunto de datos Pothole Detection publicado en Kaggle (andrewmvd/pothole-detection), con 665 imágenes de pavimento con baches. Cada imagen cuenta con un archivo de anotación en formato PASCAL VOC (XML) que contiene las coordenadas de las cajas delimitadoras de cada bache. Las carpetas del dataset son `images` y `annotations`, y los archivos se emparejan por nombre base.

3.3 Arquitectura del pipeline

El pipeline procesa cada imagen en seis etapas secuenciales. La Tabla 1 resume la operación y los parámetros de cada una.

Etapa	Operación	Parámetros
1. Espacio de color	BGR → escala de grises (luminancia ponderada)	Pesos 0.299, 0.587 y 0.114
2. Estandarización	Letterbox con escala uniforme y relleno	Lado de 512 px; relleno de valor 114
3. Suavizado	Convolución gaussiana (alternativas: mediana y bilateral)	Núcleo 5×5; $\sigma = 1.0$
4. Bordes	Sobel, Prewitt y Roberts; magnitud y umbral de Otsu	Sobel y Prewitt 3×3; Roberts 2×2
5. Esquinas	Harris y Shi-Tomasi	Harris $k = 0.04$ con umbral al 1 % del máximo; Shi-Tomasi $q = 0.01$, máximo 150 puntos, distancia mínima 7 px
6. Binarización	Otsu global y umbral adaptativo, con apertura y cierre	Adaptativo: ventana 31, $C = 10$; elemento elíptico 3×3

Tabla 1. Etapas del pipeline y parámetros utilizados.

Las etapas se aplican en el orden indicado, de modo que cada resultado intermedio es entrada de la siguiente. Los bordes y las esquinas se calculan sobre la imagen suavizada, mientras que las métricas de evaluación se calculan sobre la imagen estandarizada y las cajas transformadas al mismo sistema de coordenadas.

3.4 Implementación

El código se organizó en funciones con una responsabilidad cada una. La función `load_boxes` lee las anotaciones VOC y devuelve las cajas en coordenadas originales. La función `letterbox` transforma la imagen y las cajas a la resolución estándar. La función `smooth` aplica el filtro seleccionado. La función `gradient_magnitude` implementa los tres operadores mediante `cv2.Sobel` y `cv2.filter2D` con los núcleos

de Prewitt y Roberts. La función `detect_corners` calcula Harris y Shi-Tomasi, y `corner_metrics` evalúa su localización. La función `binarize` genera las máscaras de Otsu y adaptativa con limpieza morfológica. La función `process_image` encadena las seis etapas y devuelve un registro de métricas por imagen, y `save_panel` genera los paneles de visualización.

El programa se ejecuta desde la línea de comandos con los parámetros de entrada, carpeta de salida, tamaño de imagen, método de suavizado, número de imágenes a procesar y número de paneles. Sus salidas son dos archivos CSV, uno con las métricas de cada imagen y otro con el promedio de cada métrica, además de un conjunto de paneles en formato JPEG. Un script complementario genera las figuras de este documento a partir de esos archivos.

3.5 Protocolo de ejecución

La validación se realizó en dos fases. En la primera se ejecutó el pipeline sobre una muestra de 20 imágenes para verificar el funcionamiento de todas las etapas y la generación de salidas. En la segunda se procesó el conjunto completo de 665 imágenes con los mismos parámetros. En ambas fases, las 665 imágenes resultaron legibles y ninguna fue omitida. El tiempo por operador de borde se midió con el contador de alta resolución de Python y corresponde al cálculo de la magnitud del gradiente y su binarización, sin incluir la lectura de la imagen.

3.6 Resultados

La Tabla 2 presenta la comparación de los tres operadores de borde sobre el conjunto completo de imágenes. Los valores son promedios por imagen, y la Figura 1 los muestra con base en cero para evitar exagerar diferencias pequeñas.

Operador	Tiempo medio (ms)	Densidad de bordes	Energía ROI	Precisión ROI
Sobel	0.914	0.1740	0.2080	0.2437
Prewitt	0.895	0.1734	0.2080	0.2438
Roberts	0.785	0.1763	0.2073	0.2422

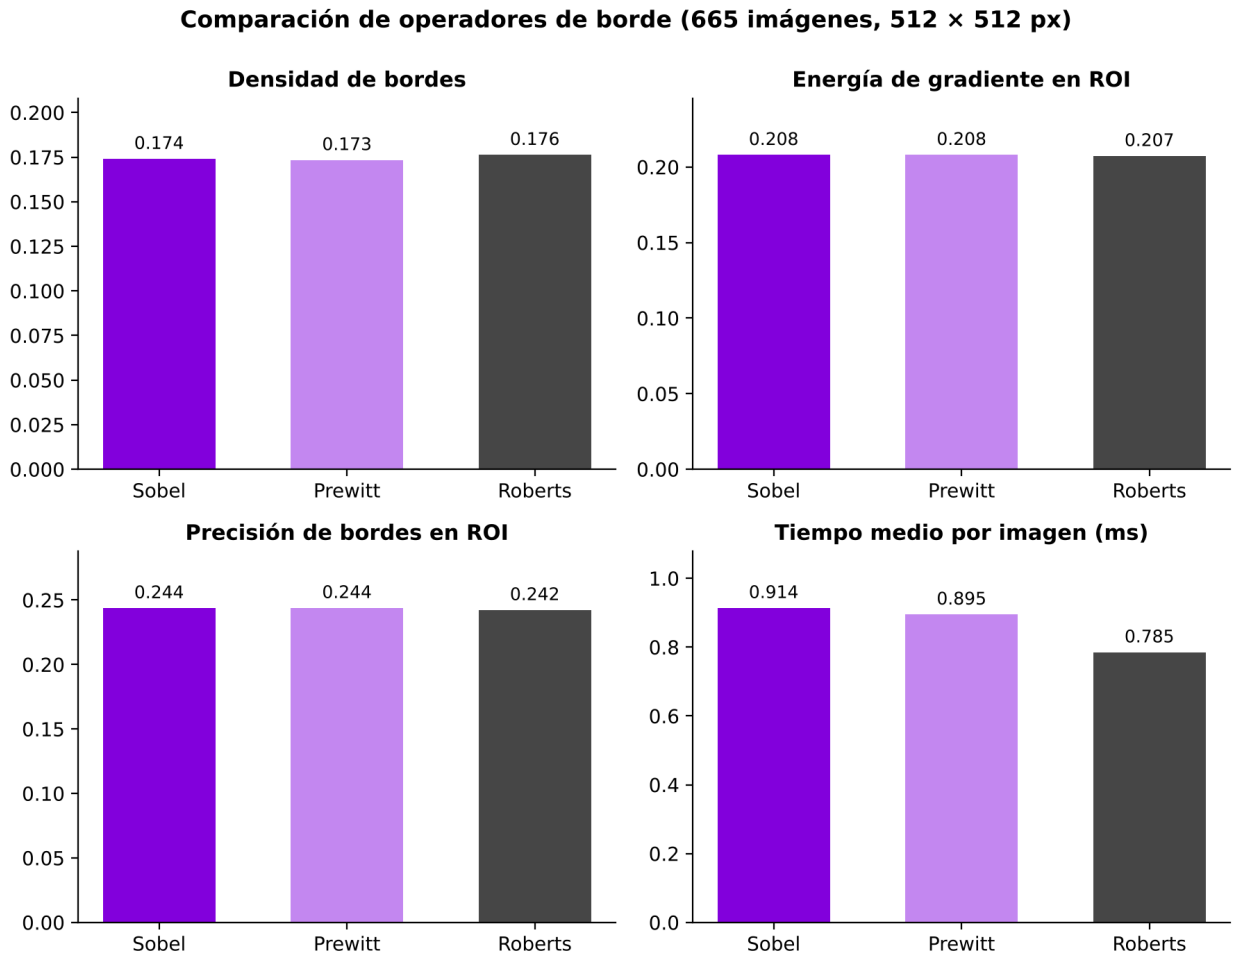


Figura 1. Comparación de operadores de borde sobre 665 imágenes. Las barras parten de cero.

La Tabla 3 presenta los resultados de la detección de esquinas. El número de puntos se reporta como promedio por imagen, la proporción en ROI indica la fracción de puntos que caen dentro de las cajas y la proporción de cajas con punto indica la fracción de baches que contienen al menos un punto.

Tabla 3. Detección de esquinas y puntos de interés (665 imágenes).

Detector	Puntos por imagen	Proporción de puntos en ROI	Cajas con al menos un punto
Shi-Tomasi	150.0 (límite)	0.332	0.938
Harris	841.6	0.300	0.981

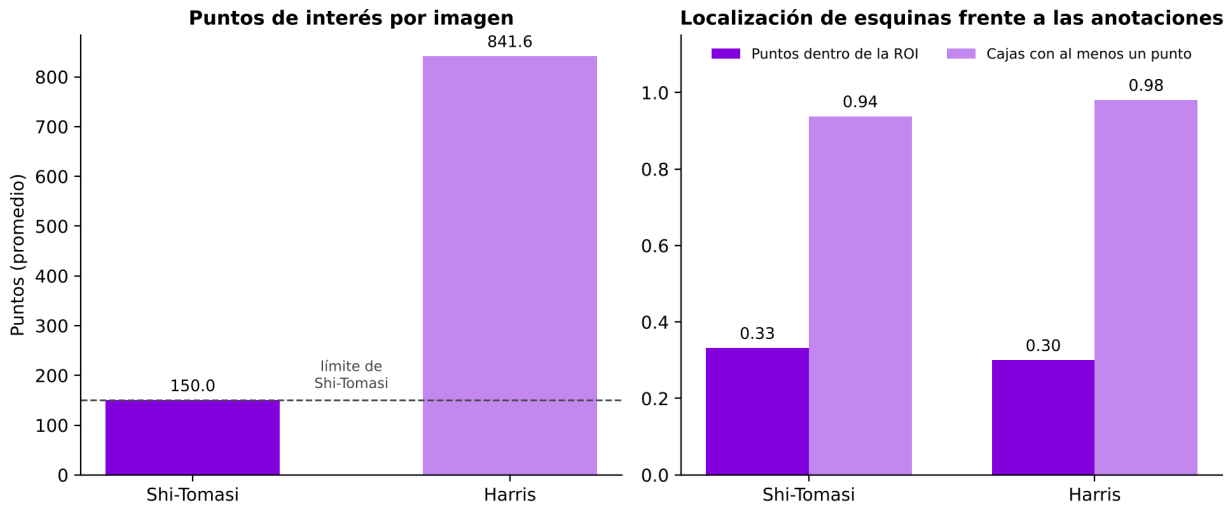


Figura 2. Número de puntos por imagen (izquierda) y localización de esquinas frente a las anotaciones (derecha).

La Tabla 4 presenta los resultados de la binarización. La fracción de primer plano indica la proporción de píxeles clasificados como región oscura.

Método	IoU medio	Fracción de píxeles en primer plano
Otsu global	0.1193	0.530
Umbral adaptativo	0.1080	0.096

Tabla 4. Binarización frente a la máscara de referencia (665 imágenes).

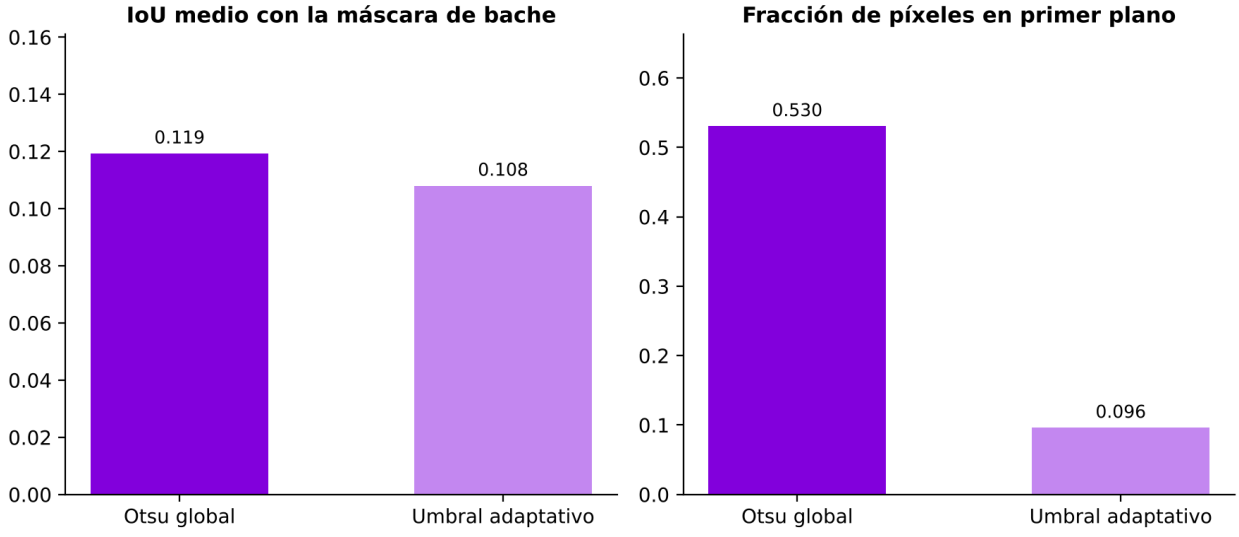


Figura 3. IoU medio y fracción de píxeles en primer plano por método de binarización.

Para verificar la estabilidad de las métricas, la Tabla 5 compara los promedios de la muestra de 20 imágenes con los del conjunto completo. Las diferencias son pequeñas en la densidad de bordes y en las proporciones en ROI, lo que sugiere que la muestra inicial era representativa para las métricas de borde. En la binarización, la diferencia en IoU fue mayor, lo que indica mayor variabilidad entre imágenes en ese método.

Métrica	**Muestra (20 imágenes)**	**Conjunto completo (665 imágenes)**
Densidad de bordes, Sobel	0.1594	0.1740
Energía en ROI, Sobel	0.1988	0.2080
Precisión en ROI, Sobel	0.2317	0.2437
Proporción de puntos en ROI, Shi-Tomasi	0.270	0.332
Proporción de puntos en ROI, Harris	0.277	0.300
IoU, Otsu global	0.0995	0.1193
IoU, umbral adaptativo	0.1064	0.1080

Tabla 5. Comparación entre la muestra piloto y el conjunto completo.

3.7 Análisis de resultados

Primero, los tres operadores de borde no son distinguibles con las métricas actuales. Las diferencias en energía en ROI y en precisión en ROI son inferiores a 0.003, y la densidad de bordes difiere menos de 0.003 entre Sobel y Roberts. Roberts es el más rápido, con una reducción de aproximadamente 15 % en el tiempo medio frente a Sobel. Sin embargo, esta diferencia de velocidad es pequeña en términos absolutos, menor a un milisegundo por imagen. Para afirmar que un operador supera a otro, sería necesario aplicar una prueba estadística sobre pares de imágenes, lo que queda como trabajo pendiente.

Segundo, la evaluación carece de una línea base. La energía en ROI de 0.21 solo es significativa si se compara con la fracción del área total que ocupan las cajas. Si esa fracción fuera cercana a 0.20, un operador aleatorio obtendría valores similares, y las métricas actuales no permitirían distinguirlo de un operador útil. Esta es la limitación más importante del protocolo de evaluación actual.

Tercero, la binarización no segmenta los baches de forma útil. Un IoU medio de 0.11 a 0.12 indica un solapamiento bajo con las anotaciones. El método de Otsu clasifica

como primer plano el 53 % de los píxeles, lo que indica que el umbral global es demasiado permisivo para escenas con pavimento oscuro en amplias zonas. El umbral adaptativo reduce la fracción de primer plano a 9.6 %, pero no mejora el solapamiento, lo que sugiere que la oscuridad local no es una señal suficiente por sí sola para distinguir un bache.

Cuarto, el detector Shi-Tomasi está saturado. En todas las imágenes devuelve el límite de 150 puntos, por lo que su conteo no aporta información sobre el contenido de la escena. Su proporción de puntos en ROI (0.33) debe interpretarse con esa restricción.

Quinto, el detector de Harris presenta una cobertura engañosa. Produce cerca de 842 puntos por imagen, por lo que la proporción de cajas con al menos un punto (0.98) es consecuencia del volumen de detecciones y no de su calidad. La proporción de puntos dentro de la ROI (0.30) es la métrica relevante, y es baja, de modo que la mayoría de los puntos de Harris corresponde a textura del pavimento fuera de los baches.

3.8 Gestión del proyecto

El código, la documentación y los resultados tabulados se versionaron en un repositorio de Git. La práctica se incorporó como una carpeta numerada dentro del repositorio de la asignatura, con su propio archivo de dependencias, su README con glosario, el resumen de métricas y las figuras. El conjunto de datos y las imágenes de los paneles no se versionan por su tamaño y por la licencia del dataset. Los archivos CSV de métricas y las figuras sí se incluyen para permitir la verificación de las cifras reportadas.

4. Conclusiones

Se diseñó e implementó un pipeline de PDI de seis etapas que procesó las 665 imágenes del dataset sin omisiones. El pipeline genera de forma reproducible las métricas por imagen, el resumen estadístico y los paneles de visualización de cada etapa. Con ello se cumplieron los objetivos técnicos de conversión a escala de grises, estandarización, suavizado, detección de bordes con tres operadores, detección de esquinas y binarización.

Respecto a los operadores de borde, Sobel, Prewitt y Roberts produjeron resultados prácticamente equivalentes en las métricas evaluadas. Roberts fue el más rápido, pero la diferencia en tiempo es pequeña y no hay evidencia de que sea superior en precisión. Por lo tanto, la elección del operador en una aplicación real debe basarse en requisitos de robustez frente al ruido y de costo computacional, no en las cifras de esta práctica.

Respecto a la binarización, los resultados no son suficientes para segmentar los baches. Un IoU de alrededor de 0.11 indica que el método de umbral, con o sin adaptación, no distingue de forma confiable las regiones dañadas del pavimento. Este hallazgo es importante para el diseño del sistema: el PDI clásico no debe presentarse como detector final, sino como generador de regiones candidatas que requiere filtrado adicional.

Respecto a las esquinas, Shi-Tomasi está limitado por el número máximo de puntos, y Harris produce un volumen de detecciones que no se traduce en localización útil dentro de las cajas. Ninguno de los dos detectores, con los parámetros utilizados, permite identificar baches de forma directa.

Las principales limitaciones de la práctica son la ausencia de una línea base en las métricas de localización, el uso de umbrales fijos que no se ajustaron por imagen y la evaluación exclusivamente por solapamiento, sin medir la capacidad de clasificación. Estas limitaciones se corresponden con el trabajo futuro siguiente:

- Incorporar la fracción de área de las cajas como línea base y reportar las métricas de borde en relación con ella.
- Corregir la iluminación con CLAHE antes de la binarización y comparar el resultado con el umbral de Otsu.
- Restringir el análisis a la región de carretera para reducir los falsos positivos fuera del pavimento.
- Filtrar las regiones candidatas por área geométrica y relación de aspecto.

- Pasar los recortes de las regiones candidatas a un modelo ligero, como YOLOv8-nano o MobileNet, para su clasificación, y comparar el desempeño del sistema híbrido con el del PDI aislado.
- Aplicar pruebas estadísticas pareadas, como la prueba de Wilcoxon, sobre las métricas por imagen para confirmar o descartar diferencias entre operadores.

En síntesis, el enfoque clásico aporta un punto de partida reproducible y de bajo costo, y su evaluación cuantitativa identifica con claridad dónde se requiere el aporte del aprendizaje automático. Esa delimitación es el resultado principal de la práctica.

Referencias

Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 8(6), 679–698.

Harris, C. & Stephens, M. (1988). A combined corner and edge detector. *Proceedings of the 4th Alvey Vision Conference*, 147–151.

Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66.

Prewitt, J. M. S. (1970). Object enhancement and extraction. En B. S. Lipkin y A. Rosenfeld (Eds.), *Picture Processing and Psychopictorics*. Academic Press.

Roberts, L. G. (1963). *Machine perception of three-dimensional solids*. Massachusetts Institute of Technology, Lincoln Laboratory, Technical Report 315.

Shi, J. & Tomasi, C. (1994). Good features to track. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 593–600.

Sobel, I. & Feldman, G. (1968). *A 3×3 isotropic gradient operator for image processing*. Presentado en Stanford Artificial Intelligence Project.

Documentación de OpenCV. https://docs.opencv.org/